

ANALITIK BIG DATA LANJUT

**ANALISIS SEGMENTASI PASAR DAN PREDIKSI HARGA LISTING AIRBNB DI
NEW YORK CITY TAHUN 2019 MENGGUNAKAN PENDEKATAN
UNSUPERVISED DAN SUPERVISED LEARNING**



**Alya Nabila Muliani (203012510013)
Erlangga Dewa Sakti (203012510035)
Muhammad Naufal Erza Farandi (203012510031)**

PROGRAM STUDI S2 INFORMATIKA

FAKULTAS INFORMATIKA

UNIVERSITAS TELKOM

BANDUNG

2026

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Dalam kurun satu dekade terakhir, akselerasi teknologi informasi telah menginisiasi kemunculan fenomena *sharing economy* yang memicu disrupsi radikal terhadap berbagai model bisnis konvensional. Industri pariwisata dan perhotelan menjadi salah satu sektor dengan transformasi paling progresif seiring munculnya platform akomodasi berbasis *peer-to-peer* (P2P). Hal ini terlihat dari pesatnya pertumbuhan Airbnb dan platform serupa lainnya, yang merepresentasikan model bisnis disruptif yang berpotensi mengubah lanskap industri pariwisata secara fundamental [1]. Airbnb, sebagai pionir dalam domain ini, telah mendefinisikan ulang pola konsumsi akomodasi global. Berbeda dengan model perhotelan tradisional yang bersifat tersentralisasi dan terstandarisasi, platform ini memfasilitasi transaksi langsung antara pemilik properti pribadi (*host*) dan konsumen (*guest*). Model bisnis ini tidak hanya mendiversifikasi struktur harga di pasar, tetapi juga menawarkan nilai tambah berupa pengalaman menginap yang terintegrasi secara lokal (*authenticity*) [2].

Sejalan dengan ekspansi globalnya, platform Airbnb mencatatkan volume transaksi yang signifikan di berbagai pusat metropolitan dunia, dengan New York City (NYC) muncul sebagai salah satu pasar yang paling krusial dan dinamis dalam ekosistem tersebut [3]. Peran NYC sebagai pusat keuangan global, episentrum bisnis, sekaligus destinasi pariwisata utama dunia memicu arus mobilitas manusia berskala masif yang berdampak langsung pada tingginya permintaan akomodasi yang heterogen [4]. Saat ini, skala operasional Airbnb telah terfragmentasi secara luas di lima distrik utama NYC (*boroughs*), mencakup kawasan komersial berkepadatan tinggi di Manhattan hingga wilayah permukiman di distrik luar (*outer boroughs*) seperti Queens dan Staten Island yang menawarkan struktur harga lebih kompetitif [5], [6].

Seiring dengan penetrasi pasarnya secara global, Airbnb telah membukukan volume transaksi yang substansial di berbagai pusat metropolitan dunia, di mana New York City (NYC) mengemuka sebagai salah satu pasar paling strategis dan dinamis dalam ekosistem tersebut. Posisi NYC sebagai pusat finansial, episentrum bisnis, sekaligus destinasi wisata global yang krusial memacu mobilitas manusia berskala masif, yang berkorelasi langsung terhadap tingginya permintaan akan penyediaan akomodasi yang heterogen [3]. Saat ini, jangkauan operasional Airbnb di NYC telah tersebar secara luas di lima distrik utama (*boroughs*), mulai dari kawasan komersial eksklusif di Manhattan hingga wilayah permukiman di distrik luar (*outer boroughs*) seperti Queens dan Staten Island yang menawarkan struktur harga akomodasi lebih kompetitif [5], [6].

Meskipun volume data yang tersedia sangat melimpah, data mentah (*raw data*) yang terdiri dari puluhan ribu entri numerik dan tekstual tidak dapat memberikan nilai guna tanpa proses ekstraksi informasi yang sistematis. Padahal, akurasi informasi merupakan kebutuhan krusial bagi para pemangku kepentingan; calon penyedia akomodasi memerlukan landasan empiris untuk merumuskan strategi penetapan harga (*pricing strategy*) yang kompetitif [7], [8], [9]. Di sisi lain, konsumen membutuhkan referensi tersebut untuk estimasi anggaran perjalanan mereka. Oleh karena itu, pengambilan keputusan strategis dalam ekosistem ini tidak dapat lagi didasarkan pada asumsi, melainkan harus bertransformasi menjadi pendekatan berbasis data (*data-driven*) [10], [11].

Oleh karena itu, pendekatan *Exploratory Data Analysis* (EDA) menjadi tahap krusial dan tidak terpisahkan. EDA bertindak sebagai jembatan yang mengubah kekacauan data mentah menjadi profil bisnis yang terstruktur [12], [13]. Melalui teknik peringkasan statistik dan representasi visual, analisis data awal ini diperlukan untuk memetakan karakteristik fundamental dari pasar Airbnb di New York City pada tahun 2019, menyingkap pola tersembunyi seperti segregasi harga antar wilayah, serta mengidentifikasi anomali atau pencilan data sebelum model prediksi tingkat lanjut dapat dikembangkan [14], [15], [16].

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, penelitian ini merumuskan beberapa masalah utama sebagai berikut:

1. Bagaimana bentuk distribusi harga sewa properti Airbnb di New York City dan apakah terdapat indikasi ketimpangan harga?
2. Bagaimana perbandingan harga sewa antar kelompok wilayah atau distrik yang ada di New York City?
3. Apa saja tipe kamar yang tersedia dan bagaimana pengaruh tipe kamar tersebut terhadap penetapan harga?
4. Bagaimana tingkat popularitas properti yang direpresentasikan oleh metrik ulasan dari pengguna?
5. Bagaimana pola ketersediaan properti sepanjang tahun di platform tersebut?

1.3 Tujuan Penelitian

Tujuan dari analisis data ini adalah:

1. Memetakan distribusi harga untuk memahami nilai tengah dan rentang harga yang paling umum di pasaran.
2. Mengidentifikasi wilayah paling eksklusif dan wilayah dengan penawaran paling terjangkau.
3. Menganalisis pengaruh tipe fasilitas kamar terhadap nilai ekonomi suatu properti.
4. Mengevaluasi indikator popularitas dan tingkat pergantian tamu berdasarkan rekam jejak ulasan.
5. Memahami karakteristik operasional tuan rumah melalui pola ketersediaan listing dalam durasi satu tahun.

1.4 Manfaat Penelitian

Secara akademik, penelitian ini memberikan kontribusi pada literatur mengenai aplikasi teknik statistika deskriptif dalam ranah ekonomi berbagi, serta membuktikan efektivitas EDA dalam meringkas puluhan ribu baris data menjadi indikator profil bisnis yang ringkas dan akurat. Secara praktis, hasil penelitian ini dapat dimanfaatkan oleh calon tuan rumah untuk menentukan strategi harga yang kompetitif berdasarkan lokasi dan tipe properti, serta membantu konsumen dalam merencanakan anggaran akomodasi mereka.

1.5 Batasan Penelitian

Agar penelitian lebih terarah, batasan penelitian ini adalah sebagai berikut:

1. Dataset yang digunakan adalah New York City Airbnb Open Data 2019 dari Kaggle.
2. Analisis hanya dilakukan pada listing Airbnb di wilayah New York City tahun 2019.

3. Penelitian menggunakan data historis yang tersedia pada dataset, sehingga tidak mempertimbangkan perubahan pasar setelah tahun 2019.
4. Target prediksi harga menggunakan variabel price atau transformasinya, yaitu log_price.
5. Segmentasi listing dilakukan menggunakan K-Means Clustering.
6. Model supervised learning yang dibandingkan mencakup Ridge Regression, Random Forest Regressor, dan Gradient Boosting atau XGBoost.
7. Penelitian tidak memasukkan data eksternal seperti jarak ke objek wisata, sentimen teks ulasan, fasilitas properti, kondisi ekonomi, musim, atau event tertentu di New York City.
8. Kesimpulan terkait model terbaik hanya akan ditentukan setelah eksperimen dan evaluasi model dilakukan.

BAB 2

DESKRIPSI DATASET DAN EKSPLORASI DATA

2.1 Deskripsi Dataset

Penelitian ini menggunakan dataset New York City Airbnb Open Data 2019 yang tersedia pada Kaggle. Dataset ini merepresentasikan listing Airbnb di New York City pada tahun 2019. Data disimpan dalam satu tabel utama, yaitu file AB_NYC_2019.csv. Setiap baris pada tabel mewakili satu listing atau unit akomodasi Airbnb.

Pada tahap awal, dataset memiliki 48.895 baris observasi. Setiap observasi menggambarkan satu listing beserta atribut yang melekat padanya, seperti identitas listing, identitas host, lokasi, tipe kamar, harga, jumlah ulasan, rata-rata ulasan per bulan, jumlah minimum malam menginap, jumlah listing host, dan ketersediaan dalam satu tahun.

Secara umum, dataset ini memiliki kombinasi fitur numerik dan kategorikal. Fitur numerik mencakup latitude, longitude, price, minimum_nights, number_of_reviews, reviews_per_month, calculated_host_listings_count, dan availability_365. Fitur kategorikal mencakup name, host_name, neighbourhood_group, neighbourhood, room_type, dan last_review. Fitur identifier mencakup id dan host_id.

Karena dataset hanya terdiri dari satu tabel, tidak terdapat hubungan antar tabel yang perlu dijelaskan seperti pada basis data relasional. Namun, keterkaitan antarfitur tetap dapat dianalisis. Misalnya, fitur neighbourhood_group dan neighbourhood berkaitan dengan lokasi listing, fitur room_type berkaitan dengan jenis akomodasi, fitur price menjadi target utama dalam prediksi harga, sedangkan fitur number_of_reviews dan reviews_per_month dapat digunakan sebagai indikator aktivitas listing.

2.2 Deskripsi Fitur

Dalam penelitian ini, tidak semua fitur digunakan secara langsung untuk pemodelan. Fitur identifier seperti id dan host_id tidak digunakan sebagai prediktor utama karena lebih berfungsi sebagai penanda unik. Fitur teks seperti name dan host_name juga tidak digunakan dalam model dasar karena memerlukan pemrosesan teks tambahan. Namun, fitur lokasi, tipe kamar, harga, minimum nights, ulasan, jumlah listing host, dan availability digunakan karena memiliki relevansi langsung terhadap segmentasi dan prediksi harga.

Kamus Data (Penjelasan Kolom)

- **id**: ID unik untuk setiap properti.
- **host_id**: Identitas dari sang pemilik properti.
- **neighbourhood_group**: Wilayah besar / Kabupaten (seperti Manhattan, Brooklyn).
- **neighbourhood**: Area spesifik / Kelurahan di dalam wilayah besar tersebut.
- **latitude / longitude**: Koordinat peta lokasi properti.
- **room_type**: Tipe properti (Apakah penyewa menyewa seluruh rumah/apartemen, atau hanya satu kamar saja?).
- **price**: Harga sewa per malam (dalam dolar).
- **minimum_nights**: Syarat minimal menginap (membantu membedakan penyewa harian vs jangka panjang).
- **number_of_reviews**: Berapa kali properti ini pernah diulas (menunjukkan seberapa sering disewa).
- **last_review**: Tanggal ulasan terakhir diberikan.
- **reviews_per_month**: Rata-rata ulasan yang masuk tiap bulan (indikator tingkat kelulusan properti).
- **calculated_host_listings_count**: Jumlah properti yang dimiliki oleh satu pemilik yang sama (menandakan host perorangan vs juragan properti).
- **availability_365**: Ketersediaan properti sepanjang tahun atau 365 hari (angka rendah berarti tempat ini sering penuh dipesan).

Gambar 1. Detail Fitur Dataset

2.3 Statistik Deskriptif


Statistik deskriptif digunakan untuk memahami karakteristik awal data. Analisis ini mencakup ukuran pemusatan, penyebaran, nilai minimum, nilai maksimum, median, dan kuartil. Pada dataset Airbnb, statistik deskriptif penting terutama untuk fitur numerik seperti `price`, `minimum_nights`, `number_of_reviews`, `reviews_per_month`, `calculated_host_listings_count`, dan `availability_365`.

Berdasarkan EDA awal, harga listing Airbnb menunjukkan variasi yang cukup besar. Sebagian besar listing berada pada rentang harga yang relatif umum, tetapi terdapat beberapa listing dengan harga sangat tinggi. Hal ini menyebabkan distribusi harga menjadi tidak simetris dan memiliki ekor panjang ke arah kanan. Oleh karena itu, median lebih representatif dibandingkan rata-rata untuk menggambarkan harga yang umum ditemukan di pasar.

Selain harga, fitur `minimum_nights` juga perlu diperhatikan karena dapat menunjukkan strategi operasional host. Listing dengan `minimum_nights` rendah cenderung lebih fleksibel untuk penyewaan jangka pendek, sedangkan listing dengan `minimum_nights` tinggi dapat menunjukkan kebijakan khusus atau orientasi penyewaan jangka menengah. Fitur `availability_365` juga penting karena menunjukkan seberapa sering listing tersedia untuk dipesan dalam satu tahun.

2.4 Analisis Distribusi Harga

Karakteristik variabel `price` dianalisis secara statistik untuk menentukan kelayakannya dalam pemodelan regresi supervised. Berdasarkan data mentah, sebaran harga sewa Airbnb NYC menunjukkan tingkat kemiringan positif yang sangat ekstrem (highly right-skewed) dengan indeks skewness mencapai 19.12.



Gambar 2. Perbandingan Data dengan Outlayer dan Tanpa Outlayer

Statistik deskriptif harga sewa riil (non-capped) menunjukkan:

- Rata-rata tarif sewa harian (mean) adalah \$152.72.
- Nilai tengah (median) populasi berada pada angka \$106.00.
- Deviasi standar (standard deviation) mencapai \$240.15, merepresentasikan rentang varians yang sangat lebar dengan nilai maksimum mencapai \$10.000.00 per malam.

Varians ekstrem ini disebabkan oleh kehadiran penginapan segmen mewah (luxury listings) yang bertindak sebagai pencilan (outliers). Guna memitigasi dampak negatif pencilan terhadap sensitivitas algoritma regresi, dirancang dua langkah rekayasa fitur (feature engineering):

1. Pembatasan Nilai Pencilan: Metode penapisan batas atas diterapkan menggunakan persentil ke-99 (99th percentile). Dari hasil komputasi, batas persentil ke-99 berada di angka \$799.00. Setiap nilai price yang melebihi batas ini diturunkan nilainya secara paksa (capped) menjadi \$799.00 (price_capped). Strategi ini memangkas varians liar tanpa membuang baris observasi potensial.
2. Transformasi Logaritma: Meskipun harga ekstrem sudah dibatasi, data harga sewa masih terdistribusi sangat timpang (sebagian besar kamar bertarif murah, namun ditarik oleh segelintir harga sangat mahal). Dalam istilah statistik, kondisi ini disebut memiliki kemiringan (skewness) yang tinggi. Agar dapat memprediksi harga dengan adil, dilakukan perapatan jarak harga yang timpang tersebut menggunakan rumus Logaritma Natural:

$$y' = \log(1 + \text{price capped})$$

Rumus ini bekerja dengan cara merapatkan jarak nilai ekstrem tanpa merusak urutan aslinya. Penerapan trik matematika ini berhasil menurunkan ke-jomplang-an (*skewness*) data secara drastis dari 19.12 **menjadi hanya** 0.55 (angka di bawah 1.0 dianggap sudah sangat seimbang dan mendekati kurva normal yang simetris), sehingga data menjadi jauh lebih mudah dipelajari oleh model komputer.

2.5 Analisis Lokasi dan Tipe Kamar

Lokasi administratif (neighbourhood_group) dan jenis akomodasi (room_type) merupakan dua prediktor kategorikal terpenting dalam memetakan variasi harga sewa.

cross-tabulation di bawah ini menyajikan sebaran frekuensi unit akomodasi berdasarkan kombinasi wilayah distrik dan tipe kamar di seluruh New York City:

Tabel 1. Frekuensi Unit Akomodasi

Borough	Entire home/apt	Private room	Shared room	Total Listing	Persentase (%)
Manhattan	13.199	7.982	480	21.661	44.31
Brooklyn	9.559	10.132	413	20.104	41.13
Queens	2096	3.372	198	5.666	11.59
Bronx	376	562	60	1.091	2.23
Staten Island	176	188	9	373	0.74
Total	25.409	22.326	1.160	48.884	100

Berdasarkan struktur demografi pasar tersebut, Manhattan dan Brooklyn menguasai pasokan pasar secara dominan dengan persentase kumulatif mencapai 85.44% dari total listing aktif.

Analisis nilai ekonomi dari masing-masing kategori mengungkapkan adanya perbedaan tarif sewa yang sangat kontras:

1. Analisis Tipe Kamar:

- Entire home/apt menduduki kelas harga tertinggi dengan rata-rata \$211.79 per malam (median: \$160.00).
- Private room ditawarkan dengan rata-rata tarif menengah sebesar \$89.78 per malam (median: \$70.00).
- Shared room merupakan segmen paling murah dengan tarif rata-rata \$70.13 per malam (median: \$45.00).

2. Analisis Wilayah (*Borough*):

- Manhattan merupakan wilayah termahal dengan tarif sewa rata-rata \$196.88 per malam (median: \$150.00), yang didorong oleh tingginya konsentrasi penyewaan rumah atau apartemen utuh (13.199 unit).
- Brooklyn menempati peringkat kedua dengan rata-rata tarif sewa harian sebesar \$124.38 (median: \$90.00).
- Bronx tercatat sebagai wilayah paling terjangkau dengan tarif rata-rata \$87.50 per malam (median: \$65.00).

2.6 Hipotesis Penelitian

Berdasarkan hasil eksplorasi data mendalam dan analisis korelasi operasional di atas, penelitian ini merumuskan empat hipotesis ilmiah yang diuji kebenarannya melalui kinerja pemodelan machine learning:

- **Hipotesis 1 :** Tipe kamar (room_type) dan distrik wilayah besar (neighbourhood_group) memiliki pengaruh nonlinear yang paling kuat dan dominan dalam menentukan tingkat akurasi prediksi harga sewa properti Airbnb di New York City.
- **Hipotesis 2 :** Algoritma berbasis penguat gradien pohon keputusan (gradient boosting trees) seperti XGBoost akan menghasilkan nilai akurasi prediksi yang secara signifikan lebih tinggi dan rata-rata kesalahan (MAE) yang lebih rendah dibandingkan model parametrik linier (Ridge Regression).

- **Hipotesis 3** : Portofolio properti Airbnb NYC dapat disegmentasikan secara otomatis menggunakan K-Means ke dalam beberapa kelompok operasional yang membedakan orientasi jangka pendek (sewa harian komersial) dengan jangka panjang (sewa bulanan/korporat).
- **Hipotesis 4** : Integrasi label klaster hasil pemodelan unsupervised ke dalam algoritma regresi supervised sebagai hybrid feature mampu meningkatkan performa akurasi prediksi regresi secara signifikan.

BAB 3

PREPROCESSING DATA DAN FEATURE ENGINEERING

Data preprocessing dan Feature engineering merupakan tahapan krusial untuk mentransformasikan data mentah menjadi format yang optimal bagi algoritma machine learning. Tanpa tahapan ini, model prediktif akan rentan terhadap bias pencilan, terhambat oleh perbedaan skala, serta tidak mampu memproses informasi kategorikal secara matematis. Bab ini membahas seluruh rangkaian praproses yang diterapkan pada dataset Airbnb NYC 2019, mulai dari penanganan data hilang hingga pembagian data uji.

3.1 Identifikasi Missing Value

Missing value dapat mengganggu proses pelatihan sebagian besar algoritma supervised learning karena operasi matriks di balik algoritma tersebut membutuhkan kelengkapan data numerik. Tahap pertama preprocessing adalah melakukan identifikasi jumlah dan mekanisme terjadinya data hilang pada 48.895 baris data awal.



	missing_count	missing_pct
last_review	10051	20.56092
reviews_per_month	10051	20.56092
id	0	0.00000
host_id	0	0.00000
neighbourhood_group	0	0.00000
neighbourhood	0	0.00000
latitude	0	0.00000
longitude	0	0.00000
room_type	0	0.00000
price	0	0.00000
minimum_nights	0	0.00000
number_of_reviews	0	0.00000
calculated_host_listings_count	0	0.00000
availability_365	0	0.00000

Gambar 3. Persebaran Missing Value


Analisis Mekanisme dan Tindakan Penanganan:

1. Atribut Administrasi (name & host_name):
Kolom name dan host_name tidak disertakan dalam tabel identifikasi nilai kosong karena telah dieksklusi sejak awal pada tahap seleksi kolom relevan. Eksklusi ini bertujuan untuk menyederhanakan ruang dimensi ke dalam model regresi.
2. Atribut Ulasan (last_review & reviews_per_month):
Berdasarkan hasil analisis, data hilang ini terbukti berkorelasi sempurna ($r = 1,0$) dengan properti yang memiliki number_of_reviews = 0. Hal ini secara logis menunjukkan bahwa nilai kosong terbentuk karena properti tersebut memang belum pernah menerima pemesanan ataupun ulasan dari tamu.

Tindakan: Untuk fitur `reviews_per_month`, dilakukan imputasi konstan menggunakan nilai numerik 0,0 agar properti tanpa ulasan tetap memiliki nilai representatif tanpa harus membuang 20,56% populasi data uji yang bernilai penting bagi model. Sementara itu, atribut temporal `last_review` dieksklusi secara total dari ruang fitur prediktor karena konversinya ke bentuk numerik berpotensi memicu bias heritabilitas waktu.

3.2 Penanganan Outlier

Atribut `price` (tarif sewa harian) dan `minimum_nights` (syarat minimum menginap) memiliki distribusi dengan ekor kanan yang sangat panjang (*heavy-tailed*). Pencilan atau *outlier* ekstrem ini umumnya merepresentasikan tipe penginapan khusus (seperti *mansion* mewah atau kontrak sewa tahunan) yang perilakunya menyimpang jauh dari rata-rata pasar reguler.



Gambar 4. Perbandingan Data dengan Outlayer dan Tanpa Outlayer

Untuk memangkas dampak pencilan tanpa mengorbankan ukuran sampel (*sample size*), diterapkan metode **Pembatasan Nilai Atas (*Percentile Capping*)** pada ambang batas persentil ke-99:

$$x_{\text{capped}} = \min(x, P_{99})$$

1. **Outlier pada Harga (`price`):** Nilai batas persentil ke-99 untuk variabel harga adalah sebesar \$799.00. Seluruh nilai harga sewa di atas batas tersebut secara paksa diturunkan (*capped*) menjadi \$799.00 untuk membentuk variabel baru `price_capped`.
2. **Outlier pada Minimum Malam (`minimum_nights`):** Nilai batas persentil ke-99 untuk syarat minimum menginap adalah sebesar 45 malam. Nilai ekstrem di atas batas tersebut diturunkan menjadi 45 malam (`minimum_nights_capped`). Pembatasan ini sangat logis karena nilai riil di atas 45 malam (bahkan ada yang mencapai 1.250 malam) lebih merepresentasikan pola kontrak residensial jangka panjang, bukan akomodasi pariwisata harian.

3.3 Transformasi Log

Meskipun pencilan telah dibatasi melalui teknik *capping*, sebaran harga sewa masih menunjukkan kemiringan (*skewness*) yang tinggi. Algoritma regresi parametrik seperti *Linear Regression* atau *Ridge Regression* mensyaratkan data berdistribusi normal untuk menghasilkan estimasi koefisien yang tidak bias.

Guna mengatasi masalah ini, dilakukan transformasi logaritma natural terhadap target prediktif `price_capped`. Penggunaan logaritma natural dipilih untuk mengantisipasi nilai nol secara matematis melalui formulasi berikut:

$$y' = \log_e(1 + y)$$

Di mana y adalah nilai riil `price_capped` dan y' adalah nilai hasil transformasi.

Dampak matematis dari transformasi logaritma ini sangat signifikan terhadap bentuk kurva distribusi target:

- **Sebelum Transformasi:** Nilai *skewness* variabel `price_capped` adalah 19,12 (sangat miring ke kanan).
- **Setelah Transformasi:** Nilai *skewness* target y' turun drastis menjadi 0,55 (hampir simetris sempurna). Transformasi ini menyeimbangkan kontribusi galat antara properti berharga murah dan mahal selama proses pembaruan bobot (*weight updates*) model.

3.4 Encoding

Model machine learning berbasis operasi matriks hanya dapat memproses nilai numerik. Oleh karena itu, fitur kategorikal penting dalam dataset harus diubah ke bentuk representasi biner menggunakan teknik One-Hot Encoding.

Fitur kategorikal yang disandi meliputi:

- `room_type` (3 kategori unik): Dikonversi menjadi tiga kolom biner independen:
- `room_Entire home/apt`
- `room_Private room`
- `room_Shared room`

`neighbourhood_group` (5 kategori unik): Dikonversi menjadi lima kolom biner independen:

- `group_Manhattan`
- `group_Brooklyn`
- `group_Queens`
- `group_Bronx`
- `group_Staten Island`

Untuk fitur `neighbourhood` yang memiliki kardinalitas sangat tinggi (221 area mikro unik), penerapan One-Hot Encoding secara langsung dihindari karena akan memicu masalah Curse of Dimensionality (peningkatan dimensi yang ekstrem namun miskin informasi). Dalam eksperimen ini, fitur `neighbourhood` diabaikan atau didorong representasinya secara spasial melalui koordinat numerik halus `latitude` dan `longitude` yang jauh lebih kaya informasi geografis kontinu.

3.5 Scaling

Fitur numerik operasional dalam dataset memiliki rentang skala yang berbeda secara signifikan. Sebagai contoh, rentang koordinat `latitude` berkisar pada interval `[40,49, 40,91]`, sedangkan variabel ketersediaan `availability_365` mencakup rentang `[0, 365]`. Perbedaan skala ini dapat menyebabkan model berbasis

kalkulasi jarak seperti K-Nearest Neighbors (KNN) atau model berbasis gradien turun (Neural Network) mengabaikan fitur berskala kecil dan terlalu condong pada fitur berskala besar.

Untuk mengatasi ketimpangan skala tersebut, diterapkan standardisasi nilai menggunakan StandardScaler (Z-score normalization) pada fitur-fitur numerik operasional:

$$z = \frac{x - \mu}{\sigma}$$

Dimana :

- z adalah nilai hasil standardisasi.
- x adalah nilai asli fitur.
- μ adalah nilai rata-rata (mean) fitur pada data latih.
- σ adalah nilai deviasi standar (standard deviation) fitur pada data latih.

Fitur numerik yang ditransformasikan meliputi `minimum_nights_capped`, `number_of_reviews`, `reviews_per_month`, `availability_365`, `latitude`, dan `longitude`. Melalui standardisasi ini, seluruh fitur numerik kini berpusat pada nilai rata-rata 0,0 dengan varians konstan 1,0.

3.6 Train-Test Split

Untuk menguji performa generalisasi model secara adil pada data yang belum pernah ditemui sebelumnya (*unseen data*), dataset dipisahkan secara acak menggunakan metode *Holdout Validation* dengan proporsi 80% untuk set pelatihan (*training set*) dan 20% untuk set pengujian (*test set*).

- **Random State Control:** Proses pengacakan baris dikunci menggunakan parameter `random_state = 42` untuk menjamin konsistensi pembagian baris data pada setiap iterasi eksperimen (*reproducibility*).
- **Partisi Dimensi Data:**
 - **Data Latih (*Train Set*):** Terdiri dari 39.107 baris observasi yang digunakan penuh untuk melatih bobot internal model regresi.
 - **Data Uji (*Test Set*):** Terdiri dari 9.777 baris observasi yang diisolasi ketat dari proses pelatihan dan hanya digunakan pada akhir tahap pengujian metrik performa prediksi (R^2 , MAE, RMSE).

BAB 4

PEMILIHAN TASK DAN PEMODELAN

Pada bab ini dibahas mengenai justifikasi pemilihan tugas (task) pembelajaran, spesifikasi algoritma yang digunakan, perumusan formulasi matematis dasar pemodelan, hingga hasil evaluasi komparatif performa dari masing-masing model yang diuji dalam eksperimen.

4.1 Justifikasi Task

Eksperimen pada dataset Airbnb NYC 2019 dirancang dengan mengintegrasikan dua paradigma utama machine learning, yaitu unsupervised learning dan supervised learning. Penggunaan kedua pendekatan ini didasarkan pada karakteristik dataset serta kebutuhan analisis bisnis yang saling melengkapi. Dalam konteks pasar Airbnb, analisis tidak hanya bertujuan untuk memprediksi harga sewa, tetapi juga untuk memahami struktur pasar dan kelompok listing yang memiliki karakteristik serupa.

Pendekatan unsupervised learning digunakan untuk melakukan segmentasi listing Airbnb melalui metode clustering. Dataset Airbnb NYC 2019 tidak memiliki label segmen pasar bawaan, sehingga diperlukan metode yang mampu mengelompokkan listing secara objektif berdasarkan kemiripan karakteristiknya. Melalui clustering, listing dapat dikelompokkan ke dalam beberapa segmen, misalnya listing dengan harga rendah, listing premium, listing dengan minimum menginap panjang, atau listing dengan tingkat aktivitas ulasan yang tinggi. Hasil segmentasi ini bermanfaat untuk memberikan gambaran makro mengenai struktur pasar Airbnb di New York City serta membantu host dan platform memahami posisi kompetitif setiap jenis properti.

Sementara itu, pendekatan supervised learning digunakan untuk melakukan prediksi harga sewa listing. Task yang dipilih adalah regresi karena variabel target yang digunakan, yaitu `price_capped` atau transformasinya dalam bentuk `log_price`, merupakan variabel numerik kontinu. Model regresi digunakan untuk mempelajari hubungan antara karakteristik properti, seperti lokasi, tipe kamar, jumlah ulasan, minimum nights, jumlah listing yang dimiliki host, dan ketersediaan tahunan terhadap harga sewa. Hasil prediksi harga dapat dimanfaatkan sebagai dasar awal dalam penyusunan strategi harga yang lebih kompetitif dan berbasis data.

Dengan demikian, penggunaan kedua task tersebut dinilai relevan untuk menjawab permasalahan penelitian. Clustering digunakan untuk memahami segmentasi dan struktur pasar, sedangkan regression digunakan untuk memperkirakan harga listing berdasarkan karakteristik properti. Kombinasi keduanya diharapkan dapat menghasilkan analisis yang lebih komprehensif, tidak hanya dari sisi prediksi harga, tetapi juga dari sisi interpretasi bisnis dan rekomendasi strategi bagi host maupun platform Airbnb.

4.2 Unsupervised Learning: K-Means Clustering

K-Means Clustering digunakan untuk membentuk segmentasi pasar listing Airbnb NYC 2019. Algoritma ini dipilih karena memiliki cara kerja yang relatif sederhana, efisien untuk dataset berukuran besar, serta hasil pengelompokannya mudah diinterpretasikan secara bisnis. Dalam konteks penelitian ini, K-Means digunakan untuk mengidentifikasi kelompok listing yang memiliki karakteristik operasional serupa, seperti tingkat harga, durasi minimum menginap, jumlah ulasan, tingkat ketersediaan, dan tipe kamar.

Secara umum, K-Means bekerja dengan membagi data ke dalam sejumlah (K) cluster berdasarkan kedekatan jarak antar observasi. Setiap observasi akan ditempatkan pada cluster dengan titik pusat atau centroid terdekat. Proses ini dilakukan secara iteratif hingga posisi centroid relatif stabil dan tidak banyak terjadi perubahan anggota cluster.

4.2.1 Formulasi Matematis K-Means

K-Means mempartisi (n) data observasi ke dalam (K) cluster terpisah dengan tujuan meminimalkan nilai inertia atau Within-Cluster Sum of Squares (WCSS). Nilai WCSS menunjukkan total jarak kuadrat antara setiap data dengan centroid cluster tempat data tersebut berada. Semakin kecil nilai WCSS, semakin kompak anggota dalam suatu cluster.

Secara matematis, fungsi objektif K-Means dapat dirumuskan sebagai berikut:

$$J = \sum_{i=1}^K \sum_{x \in S_i} \|x - \mu_i\|^2$$

Keterangan:

- (J) adalah nilai objektif atau total Within-Cluster Sum of Squares (WCSS).
- (K) adalah jumlah cluster yang ditentukan.
- (S_i) adalah himpunan observasi yang masuk ke dalam cluster ke-(i).
- (x) adalah vektor fitur dari satu listing Airbnb.
- (μ_i) adalah titik pusat atau centroid dari cluster ke-(i).
- ($\|x - \mu_i\|^2$) adalah kuadrat jarak Euclidean antara data (x) dengan centroid (μ_i).

Berdasarkan rumus tersebut, K-Means berusaha mencari susunan cluster yang membuat jarak antar anggota dalam cluster menjadi sekecil mungkin. Dengan kata lain, listing yang memiliki karakteristik serupa akan ditempatkan dalam cluster yang sama, sedangkan listing dengan karakteristik berbeda akan berada pada cluster lain.

4.2.2 Fitur yang Digunakan dalam Clustering

Fitur yang digunakan dalam proses clustering dipilih berdasarkan relevansinya terhadap karakteristik bisnis listing Airbnb. Fitur-fitur tersebut adalah:

1. `price_capped`, yaitu harga listing setelah nilai pencilan ekstrem dibatasi menggunakan persentil ke-99.
 2. `minimum_nights_capped`, yaitu jumlah minimum malam menginap setelah nilai ekstrem dibatasi.
 3. `number_of_reviews`, yaitu jumlah ulasan yang dapat merepresentasikan tingkat aktivitas atau popularitas listing.
 4. `availability_365`, yaitu jumlah hari ketersediaan listing dalam satu tahun.
 5. `room_type`, yaitu tipe kamar yang telah diubah ke bentuk numerik menggunakan one-hot encoding.
- Fitur `price_capped` digunakan untuk merepresentasikan tingkat harga listing tanpa dipengaruhi secara berlebihan oleh pencilan ekstrem. Fitur `minimum_nights_capped` digunakan untuk menangkap pola kebijakan durasi minimum menginap, apakah listing lebih diarahkan untuk

penyewaan jangka pendek atau jangka panjang. Fitur `number_of_reviews` merepresentasikan tingkat aktivitas atau popularitas listing, sedangkan `availability_365` menunjukkan seberapa sering properti tersedia untuk dipesan dalam satu tahun. Sementara itu, `room_type` digunakan karena tipe kamar merupakan salah satu faktor utama yang membedakan kelas ekonomi listing Airbnb, misalnya `entire home/apt`, `private room`, dan `shared room`.

4.2.3 Standardisasi Fitur

Sebelum algoritma K-Means dijalankan, seluruh fitur numerik distandardisasi menggunakan `StandardScaler`. Tahap standardisasi diperlukan karena K-Means menghitung kedekatan antar data berdasarkan jarak Euclidean. Jika fitur memiliki skala yang berbeda terlalu jauh, maka fitur dengan rentang nilai besar dapat mendominasi proses pembentukan cluster.

Sebagai contoh, fitur `availability_365` memiliki rentang nilai 0 sampai 365, sedangkan fitur hasil one-hot encoding dari `room_type` hanya memiliki nilai 0 atau 1. Tanpa standardisasi, fitur `availability_365` dapat memberikan pengaruh yang lebih besar dalam perhitungan jarak dibandingkan fitur lainnya. Oleh karena itu, standardisasi dilakukan agar setiap fitur memiliki skala yang seimbang dan kontribusinya terhadap proses clustering menjadi lebih adil.

Standardisasi dilakukan menggunakan rumus:

$$\left[z = \frac{x - \mu}{\sigma} \right]$$

Keterangan:

- (z) adalah nilai hasil standardisasi.
- (x) adalah nilai asli fitur.
- (μ) adalah rata-rata fitur.
- (σ) adalah standar deviasi fitur.

Dengan standardisasi ini, setiap fitur numerik memiliki rata-rata mendekati 0 dan standar deviasi mendekati 1, sehingga proses clustering menjadi lebih stabil.

4.2.4 Penentuan K Optimal dengan Silhouette Score

Salah satu tantangan utama dalam K-Means adalah menentukan jumlah cluster (K) yang paling tepat. Jika jumlah cluster terlalu sedikit, maka segmentasi yang terbentuk menjadi terlalu umum dan kurang informatif. Sebaliknya, jika jumlah cluster terlalu banyak, maka hasil segmentasi menjadi terlalu terpecah dan sulit diinterpretasikan secara bisnis.

Pada penelitian ini, jumlah cluster optimal ditentukan menggunakan **Silhouette Score**. Silhouette Score digunakan untuk mengukur kualitas pengelompokan data dengan membandingkan jarak rata-rata suatu data terhadap anggota cluster-nya sendiri dan jarak rata-rata terhadap cluster lain yang paling dekat.

Secara matematis, Silhouette Score untuk satu titik data (i) dirumuskan sebagai berikut:


$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Di mana:

- $(s(i))$ adalah nilai Silhouette untuk data ke-(i).
- $(a(i))$ adalah rata-rata jarak data ke-(i) terhadap seluruh anggota dalam cluster yang sama.
- $(b(i))$ adalah rata-rata jarak terkecil data ke-(i) terhadap anggota cluster lain terdekat.
- Nilai $(s(i))$ berada pada rentang -1 sampai 1.

Interpretasi nilai Silhouette Score adalah sebagai berikut. Nilai yang mendekati 1 menunjukkan bahwa data berada pada cluster yang tepat dan jauh dari cluster lain. Nilai mendekati 0 menunjukkan bahwa data berada di batas antara dua cluster. Sementara itu, nilai negatif menunjukkan bahwa data kemungkinan lebih cocok masuk ke cluster lain.

Pada eksperimen ini, nilai (K) diuji dari (K=2) sampai (K=19) menggunakan sampel acak sebesar 5.000 baris data untuk menjaga efisiensi komputasi. Hasil evaluasi ditunjukkan pada Gambar 4.



Gambar 5. Evaluasi K Optimal Menggunakan Silhouette Score

Gambar 5.1 digunakan untuk menunjukkan proses pemilihan jumlah cluster optimal. Berdasarkan grafik tersebut, nilai Silhouette Score meningkat dari K=2 hingga mencapai nilai tertinggi pada K=6. Setelah K=6, nilai Silhouette Score cenderung menurun atau berfluktuasi. Hal ini menunjukkan bahwa penambahan jumlah cluster setelah K=6 tidak memberikan peningkatan kualitas segmentasi yang konsisten.

Berdasarkan hasil evaluasi, nilai Silhouette Score tertinggi diperoleh pada (K=6) dengan skor sebesar 0,4975. Oleh karena itu, jumlah cluster optimal yang digunakan dalam penelitian ini adalah 6 cluster. Nilai tersebut menunjukkan bahwa struktur segmentasi cukup terbentuk, meskipun belum sepenuhnya terpisah secara sempurna. Kondisi ini wajar karena pasar Airbnb memiliki karakteristik yang saling tumpang tindih, terutama antara listing dengan tipe kamar, lokasi, dan rentang harga yang berdekatan.

Dengan menggunakan (K=6), hasil clustering tidak hanya memberikan pembagian data secara matematis, tetapi juga menghasilkan segmentasi yang dapat diinterpretasikan secara bisnis. Setiap cluster kemudian dianalisis lebih lanjut berdasarkan median harga, minimum nights, jumlah ulasan, availability, dan tipe kamar mayoritas untuk memahami karakteristik masing-masing segmen pasar Airbnb NYC 2019.

4.3 Supervised Learning: Ridge Regression

Model supervised pertama yang digunakan adalah Linear Regression. Model ini berfungsi sebagai baseline atau pembandingan awal karena memiliki struktur yang sederhana dan mudah diinterpretasikan. Linear Regression berusaha memodelkan hubungan linier antara fitur input dan target harga.

Secara umum, model Linear Regression dapat dirumuskan sebagai berikut:

$$\mathcal{L}_{\text{Ridge}}(\beta) = \sum_{i=1}^n (y_i - x_i^T \beta)^2 + \alpha \sum_{j=1}^p \beta_j^2$$

di mana $\hat{y}$ adalah nilai prediksi harga, β_0 adalah intercept, β_1 sampai β_n adalah koefisien model, dan X_1 sampai X_n adalah fitur prediktor.

Kelebihan Linear Regression adalah mudah dipahami, cepat dilatih, dan dapat memberikan gambaran awal mengenai hubungan antar fitur dan harga. Namun, model ini memiliki keterbatasan karena mengasumsikan hubungan linier. Dalam konteks Airbnb, hubungan antara harga dan fitur seperti lokasi, tipe kamar, ulasan, serta ketersediaan cenderung bersifat non-linear. Misalnya, pengaruh lokasi Manhattan terhadap harga tidak selalu bertambah secara linier, dan kombinasi antara tipe kamar serta lokasi dapat menghasilkan efek harga yang kompleks. Oleh karena itu, Linear Regression digunakan sebagai baseline, bukan sebagai model final utama.

Pada hasil eksperimen, Linear Regression menghasilkan R^2 sebesar 0,509, MAE sebesar 54,222, dan RMSE sebesar 103,485. Hasil ini menunjukkan bahwa model linier mampu menangkap sebagian pola harga, tetapi performanya masih berada di bawah model non-linear seperti Random Forest dan XGBoost.

4.4 Supervised Learning: Random Forest

Random Forest Regressor digunakan sebagai model supervised non-linear berbasis ensemble learning. Model ini membangun banyak pohon keputusan secara paralel menggunakan teknik bootstrap sampling. Setiap pohon dilatih pada subset data yang berbeda, kemudian hasil prediksi akhir diperoleh dari rata-rata prediksi seluruh pohon.

$$\hat{f}(x) = \frac{1}{T} \sum_{t=1}^T f_t(x)$$

di mana T adalah jumlah pohon, $f_t(x)$ adalah prediksi dari pohon ke- t , dan $\hat{y}$ adalah prediksi akhir model.

Random Forest dipilih karena mampu menangkap hubungan non-linear dan interaksi antar fitur tanpa memerlukan asumsi hubungan linier. Model ini juga relatif tahan terhadap outlier dan mampu menangani kombinasi fitur numerik maupun kategorikal hasil encoding. Dalam konteks Airbnb, Random Forest dapat

mempelajari pola kompleks seperti kombinasi antara tipe kamar, lokasi, jumlah ulasan, dan ketersediaan properti.

Pada eksperimen ini, Random Forest menggunakan $n_estimators = 100$, $random_state = 42$, dan $n_jobs = -1$. Parameter $n_estimators = 100$ dipilih untuk menghasilkan jumlah pohon yang cukup stabil tanpa membebani komputasi secara berlebihan. Hasil evaluasi menunjukkan bahwa Random Forest memperoleh R^2 sebesar 0,610, MAE sebesar 48,399, dan RMSE sebesar 93,310. Nilai ini menunjukkan peningkatan yang cukup jelas dibandingkan baseline Linear Regression.

4.5 Supervised Learning: Gradient Boosting/XGBoost

Sebagai model pembanding tercanggih di kelas non-linear, digunakan algoritma XGBoost (eXtreme Gradient Boosting) yang menerapkan konsep ensemble boosting.

Berbeda dengan Random Forest yang melatih pohon secara independen, XGBoost melatih pohon keputusan secara sekuensial. Setiap pohon baru ditugaskan untuk mengoreksi kesalahan sisaan (*residuals*) yang dihasilkan oleh kombinasi pohon-pohon sebelumnya. Fungsi kerugian objektif pada iterasi ke- t dirumuskan dengan menambahkan penalti keteraturan pohon untuk mencegah gejala *overfitting*:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

Di mana parameter penalti kompleksitas struktur pohon $\Omega(f_t)$ adalah:

$$\Omega(f_t) = \gamma T_L + \frac{1}{2} \lambda \sum_{j=1}^{T_L} w_j^2$$

4.6 Hyperparameter Tuning

Hyperparameter tuning dilakukan untuk memastikan model yang digunakan memiliki konfigurasi parameter yang stabil dan relevan dengan karakteristik data. Pada penelitian ini, tuning dilakukan dalam bentuk eksperimen parameter terkontrol. Tuning paling eksplisit dilakukan pada K-Means dengan menguji beberapa nilai K menggunakan Silhouette Score. Sementara itu, pada model supervised, parameter dipilih berdasarkan konfigurasi umum yang stabil, pertimbangan efisiensi komputasi, dan kemampuan model dalam menghasilkan performa yang baik pada data uji.

Tabel 2. Konfigurasi Hyperparameter Model

Model	Hyperparameter Utama	Nilai yang Digunakan	Alasan Pemilihan
K-Means	n_clusters	6	Dipilih berdasarkan Silhouette Score tertinggi
K-Means	n_init	10	Mengurangi risiko hasil cluster buruk akibat inisialisasi centroid
Linear Regression	default parameter	default	Digunakan sebagai baseline sederhana
KNN Regressor	n_neighbors	5	Menangkap pola prediksi berdasarkan kedekatan data
Random Forest	n_estimators	100	Menyeimbangkan performa dan efisiensi komputasi
Random Forest	random_state	42	Menjamin reproducibility
XGBoost	n_estimators	100	Jumlah estimator cukup stabil untuk eksperimen awal
XGBoost	learning_rate	0,1	Membuat proses boosting lebih stabil
XGBoost	random_state	42	Menjamin reproducibility

Metrik evaluasi yang digunakan untuk model supervised adalah R^2 , MAE, dan RMSE. R^2 digunakan untuk melihat seberapa besar variasi target yang dapat dijelaskan model. MAE digunakan untuk mengetahui rata-rata kesalahan prediksi dalam satuan dolar, sehingga mudah diinterpretasikan secara bisnis. RMSE digunakan untuk memberi penalti lebih besar pada kesalahan prediksi yang ekstrem. Untuk model unsupervised, metrik evaluasi yang digunakan adalah Silhouette Score karena dataset tidak memiliki label cluster asli.


Keterbatasan tuning pada penelitian ini adalah belum dilakukan pencarian hyperparameter secara lebih luas menggunakan GridSearchCV atau RandomizedSearchCV. Oleh karena itu, hasil tuning supervised dapat dikategorikan sebagai eksperimen terkontrol awal, sedangkan tuning K-Means sudah dilakukan secara lebih sistematis melalui pencarian K optimal.

4.5 Evaluasi Model Supervised

Evaluasi model supervised dilakukan pada data uji sebesar 20% dari total data setelah preprocessing. Model dilatih menggunakan target log_price, kemudian hasil prediksi dikembalikan ke skala harga asli menggunakan inverse transformation agar nilai MAE dan RMSE dapat dibaca dalam satuan dolar. Dengan demikian, R^2 pada tabel berikut dihitung pada skala log_price, sedangkan MAE dan RMSE dihitung pada skala harga asli setelah transformasi balik.


Tabel 3. Hasil Evaluasi Model Supervised pada Full Data

Model	R^2	MAE (USD)	RMSE (USD)
Linear Regression	0,509	54,222	103,485
KNN Regressor	0,543	52,595	98,589
Random Forest	0,610	48,399	93,310
XGBoost	0,617	48,395	94,471



Gambar 6. Actual vs Predicted untuk Model Supervised

Gambar 6 memperlihatkan kedekatan antara harga aktual dan harga prediksi. Garis merah putus-putus menunjukkan prediksi ideal. Semakin dekat titik terhadap garis merah, semakin baik prediksi model. Model tree-based terlihat lebih baik dibandingkan baseline linier, meskipun prediksi pada harga tinggi masih cenderung lebih sulit.




Gambar 7. Perbandingan MAE Model Supervised

Gambar 7 memperjelas perbandingan kesalahan rata-rata antar model. XGBoost dan Random Forest memiliki MAE paling rendah, sedangkan Linear Regression menjadi baseline dengan kesalahan terbesar. Berdasarkan hasil evaluasi, XGBoost menghasilkan nilai R^2 tertinggi, yaitu 0,617, dan MAE terendah, yaitu 48,395. Artinya, model XGBoost mampu menjelaskan sekitar 61,7% variasi harga pada skala log dan memiliki rata-rata kesalahan prediksi sekitar 48,40 dolar pada skala harga asli. Random Forest memiliki performa yang sangat dekat dengan XGBoost, dengan R^2 sebesar 0,610 dan MAE sebesar 48,399. Bahkan, Random Forest memiliki RMSE yang sedikit lebih rendah, yaitu 93,310 dibandingkan XGBoost sebesar 94,471. Perbedaan performa antara XGBoost dan Random Forest sangat kecil. Namun, XGBoost tetap dipilih sebagai model terbaik secara keseluruhan karena memiliki R^2 tertinggi dan MAE paling rendah.


4.5 Evaluasi Model Unsupervised

Evaluasi model unsupervised dilakukan menggunakan Silhouette Score. Berdasarkan hasil percobaan pada beberapa nilai K, jumlah cluster optimal adalah K=6 dengan Silhouette Score sebesar 0,4975. Nilai ini menunjukkan bahwa struktur cluster cukup baik dan dapat digunakan untuk segmentasi bisnis, meskipun terdapat kemungkinan beberapa listing berada pada batas antar cluster karena karakteristik pasar Airbnb yang saling tumpang tindih.




Gambar 8. Peta Persebaran Cluster pada Sample Data

Peta ini menunjukkan pola awal sebaran cluster pada sample data. Visualisasi ini berguna untuk memeriksa apakah cluster tersebar secara geografis dan apakah terdapat konsentrasi kelompok tertentu di area tertentu.



Gambar 9. Peta Persebaran Cluster pada Full Data

Peta full data menunjukkan sebaran cluster pada seluruh listing setelah model K-Means diterapkan. Walaupun cluster dibentuk berdasarkan fitur bisnis, visualisasi spasial tetap membantu melihat apakah karakteristik cluster berkaitan dengan wilayah geografis tertentu.



Gambar 10. Boxplot Harga per Cluster

Boxplot ini menunjukkan perbedaan rentang harga antar cluster. Cluster 3 memiliki median harga paling tinggi sehingga dapat diinterpretasikan sebagai segmen premium/luxury, sedangkan cluster 2 memiliki median harga paling rendah dan sesuai dengan segmen shared room murah.

Tabel 4. Profil Bisnis Setiap Cluster

Cluster	Median Harga	Median Minimum Nginap	Rata-rata Ulasan	Rata-rata Ketersediaan	Tipe Kamar Mayoritas
0	\$70	2 malam	15,2	98,7 hari	Private room
1	\$150	3 malam	15,7	74,2 hari	Entire home/apt
2	\$45	1 malam	16,2	161,7 hari	Shared room
3	\$500	3 malam	12,8	193,1 hari	Entire home/apt
4	\$130	30 malam	7,5	221,2 hari	Entire home/apt
5	\$105	2 malam	166,3	192,6 hari	Entire home/apt

Hasil tersebut menunjukkan bahwa K-Means tidak hanya membagi data secara matematis, tetapi juga menghasilkan segmen yang bermakna secara bisnis. Cluster 0 merepresentasikan pasar private room dengan harga terjangkau, Cluster 1 merepresentasikan entire home/apt standar, Cluster 2 merepresentasikan shared

room murah, Cluster 3 merepresentasikan properti premium, Cluster 4 merepresentasikan long-term stay, dan Cluster 5 merepresentasikan listing dengan aktivitas ulasan yang sangat tinggi.


4.6 Eksperimen Hybrid

Eksperimen hybrid dilakukan dengan menggabungkan hasil unsupervised learning ke dalam supervised learning. Konsepnya adalah label cluster dari K-Means digunakan sebagai fitur tambahan pada model prediksi harga. Dengan demikian, model supervised tidak hanya mempelajari fitur asli listing, tetapi juga memperoleh informasi mengenai segmen pasar tempat listing tersebut berada.

Secara teknis, label cluster diubah menjadi fitur numerik menggunakan one-hot encoding, misalnya Cluster_0, Cluster_1, dan seterusnya. Fitur cluster tersebut kemudian digabungkan ke dalam fitur supervised learning. Model terbaik dari tahap supervised kemudian dilatih ulang menggunakan fitur tambahan tersebut.


Tabel 5. Perbandingan MAE Supervised Standard dan Hybrid

Skenario	MAE Sample	MAE Full
Supervised Standard	50,049	48,395
Hybrid Supervised + Cluster	39,424	38,232



Gambar 11. Perbandingan MAE Supervised Standard dan Hybrid

Gambar ini menunjukkan bahwa penambahan label cluster menurunkan MAE pada sample data dan full data. Secara angka, hybrid tampak lebih baik, tetapi hasil ini harus dibaca bersama catatan potensi data leakage.



Gambar 12. Actual vs Predicted Model Hybrid XGBoost

Gambar ini memperlihatkan hasil prediksi model hybrid. R^2 meningkat menjadi 0,719 dan MAE turun menjadi 38,23, namun peningkatan ini tidak dapat langsung diklaim sebagai hasil final paling valid karena cluster dibentuk dengan melibatkan fitur harga.

Berdasarkan hasil perbandingan, pendekatan hybrid menurunkan MAE pada full data dari 48,395 menjadi 38,232. Secara angka, hal ini menunjukkan bahwa penambahan informasi cluster mampu memperbaiki rata-rata kesalahan prediksi harga. Namun, hasil hybrid perlu diinterpretasikan secara hati-hati. Dalam eksperimen clustering, fitur `price_capped` digunakan sebagai salah satu fitur pembentuk cluster. Jika label cluster yang dibentuk menggunakan informasi harga kemudian digunakan kembali untuk memprediksi harga, maka terdapat potensi data leakage. Dengan kata lain, model hybrid secara tidak langsung menerima informasi yang berkaitan dengan target. Oleh karena itu, hasil hybrid dalam penelitian ini lebih tepat diposisikan sebagai eksperimen tambahan, bukan sebagai model final utama.

Agar pendekatan hybrid lebih valid pada penelitian lanjutan, proses clustering untuk fitur tambahan sebaiknya dilakukan tanpa menggunakan `price_capped`. Cluster dapat dibentuk hanya berdasarkan fitur non-target, seperti `room_type`, `minimum_nights_capped`, `number_of_reviews`, `availability_365`, `latitude`, `longitude`, `calculated_host_listings_count`, dan `neighbourhood_group`. Dengan demikian, label cluster benar-benar merepresentasikan karakteristik listing tanpa membawa informasi langsung dari target harga.

4.7 Pemilihan Model Terbaik

Berdasarkan seluruh hasil eksperimen, model terbaik untuk task supervised learning adalah XGBoost Regressor. Model ini dipilih karena menghasilkan nilai R^2 tertinggi sebesar 0,617 dan MAE terendah sebesar 48,395. Nilai MAE tersebut berarti bahwa secara rata-rata prediksi harga model menyimpang sekitar 48,40 dolar dari harga aktual setelah data harga dikembalikan ke skala asli.

Meskipun Random Forest memiliki RMSE yang sedikit lebih rendah dibandingkan XGBoost, selisih performanya relatif kecil. XGBoost tetap lebih unggul secara keseluruhan karena mampu memberikan keseimbangan terbaik antara kemampuan menjelaskan variasi target dan rata-rata kesalahan prediksi. Selain itu, XGBoost juga menghasilkan feature importance yang dapat digunakan untuk memahami faktor-faktor utama yang memengaruhi harga listing.

Untuk task unsupervised learning, model terbaik adalah K-Means dengan K=6. Pemilihan ini didasarkan pada nilai Silhouette Score tertinggi sebesar 0,4975. Selain unggul secara metrik, hasil cluster yang terbentuk juga memiliki interpretasi bisnis yang jelas, seperti segmen budget, standard entire home, shared room, premium/luxury, long-term stay, dan high-review listing.

Tabel 6. Ringkasan Pemilihan Model Terbaik

Task	Model Terbaik	Metrik Utama	Alasan Pemilihan
Prediksi harga	XGBoost Regressor	$R^2 = 0,617$; MAE = 48,395; RMSE = 94,471	R^2 tertinggi dan MAE terendah pada model supervised
Segmentasi pasar	K-Means Clustering K=6	Silhouette Score = 0,4975	Nilai silhouette tertinggi dan cluster bermakna secara bisnis
Eksperimen tambahan	Hybrid Supervised + Cluster	MAE Full = 38,232	Menunjukkan potensi perbaikan, tetapi tidak dijadikan final karena potensi data leakage

Dengan demikian, model akhir yang dipilih adalah XGBoost Regressor sebagai model utama untuk prediksi harga dan K-Means Clustering dengan K=6 sebagai model utama untuk segmentasi pasar. Hybrid model digunakan sebagai eksperimen tambahan untuk menunjukkan potensi integrasi kedua pendekatan, tetapi belum dijadikan model final karena perlu validasi lebih ketat.

BAB 5

INTERPRETASI HASIL

Bab ini membahas interpretasi hasil clustering dan prediksi harga, faktor-faktor yang paling berpengaruh terhadap harga, serta rekomendasi bisnis yang dapat diambil berdasarkan hasil model. Interpretasi tidak hanya berfokus pada nilai metrik, tetapi juga diarahkan pada strategi praktis bagi host dan platform Airbnb.

5.1 Interpretasi Cluster

Hasil K-Means dengan $K=6$ menunjukkan bahwa pasar Airbnb NYC 2019 dapat dibagi menjadi enam segmen utama. Setiap cluster memiliki karakteristik harga, tipe kamar, durasi minimum menginap, ulasan, dan ketersediaan yang berbeda. Segmentasi ini penting karena strategi harga dan strategi pemasaran tidak dapat disamakan untuk semua listing.

Tabel 7. Interpretasi Bisnis Setiap Cluster

Cluster	Nama Segmen	Karakteristik Utama	Interpretasi Bisnis
0	Budget Private Room	Median harga \$70, minimum 2 malam, mayoritas private room	Cocok untuk wisatawan individu atau pasangan dengan anggaran terbatas yang tetap membutuhkan privasi
1	Standard Entire Home	Median harga \$150, minimum 3 malam, mayoritas entire home/apt	Cocok untuk keluarga atau grup kecil yang membutuhkan unit akomodasi penuh
2	Low-Budget Shared Room	Median harga \$45, minimum 1 malam, mayoritas shared room	Cocok untuk backpacker, pelancong transit, atau konsumen yang sangat sensitif terhadap harga
3	Premium/Luxury Listing	Median harga \$500, mayoritas entire home/apt, availability tinggi	Cocok untuk pasar premium dengan margin tinggi, tetapi tingkat permintaan lebih terbatas
4	Long-Term Stay	Median harga \$130, minimum 30 malam, availability tinggi, ulasan rendah	Cocok untuk penyewa bulanan, pekerja sementara, mahasiswa, atau ekspatriat
5	High-Review/High-Activity Listing	Median harga \$105, rata-rata ulasan sangat tinggi, mayoritas entire home/apt	Menunjukkan listing aktif dan populer dengan reputasi kuat di pasar

Cluster 0 merepresentasikan segmen private room dengan harga terjangkau. Segmen ini menjadi salah satu pasar utama Airbnb karena menawarkan keseimbangan antara harga murah dan privasi. Target konsumennya adalah wisatawan individu, pasangan muda, atau pelancong yang ingin menekan biaya akomodasi tanpa harus berbagi kamar secara penuh seperti shared room.

Cluster 1 merepresentasikan entire home/apt standar dengan harga menengah. Segmen ini cocok untuk keluarga, kelompok teman, atau tamu yang membutuhkan ruang penuh selama menginap. Nilai median harga \$150 menunjukkan bahwa segmen ini berada di kelas menengah dan memiliki daya tarik yang cukup kuat bagi wisatawan yang mengutamakan kenyamanan.

Cluster 2 adalah segmen shared room dengan harga paling rendah. Median harga \$45 dan minimum menginap 1 malam menunjukkan bahwa segmen ini sangat fleksibel dan terjangkau. Namun, rata-rata ketersediaan yang cukup tinggi dapat mengindikasikan bahwa shared room memiliki tingkat permintaan yang lebih rendah dibandingkan private room atau entire home/apt.

Cluster 3 merupakan segmen premium atau luxury listing. Median harga \$500 menunjukkan bahwa listing dalam cluster ini berada pada kelas harga tinggi. Tingkat availability yang tinggi dapat mengindikasikan bahwa properti premium tidak selalu penuh sepanjang tahun. Strategi pada segmen ini sebaiknya tidak hanya mengejar okupansi tinggi, tetapi juga menekankan margin keuntungan per pemesanan, kualitas fasilitas, lokasi eksklusif, dan pengalaman menginap premium.

Cluster 4 merepresentasikan long-term stay. Ciri paling kuat dari cluster ini adalah median minimum menginap 30 malam. Segmen ini tidak terlalu menargetkan wisatawan harian, melainkan penyewa jangka menengah seperti pekerja proyek, mahasiswa, ekspatriat, atau tamu yang membutuhkan akomodasi bulanan. Rata-rata ulasan yang rendah tidak selalu berarti kualitas buruk, tetapi dapat disebabkan oleh frekuensi pergantian tamu yang lebih rendah.

Cluster 5 merupakan segmen high-review atau high-activity listing. Cluster ini memiliki rata-rata ulasan sangat tinggi, yaitu 166,3 ulasan. Hal ini menunjukkan bahwa listing dalam cluster ini memiliki aktivitas pemesanan yang tinggi dan kemungkinan memiliki reputasi yang kuat. Listing pada cluster ini dapat dijadikan contoh strategi pengelolaan yang efektif.

Secara keseluruhan, hasil clustering menunjukkan bahwa pasar Airbnb NYC tidak homogen. Setiap segmen memiliki logika bisnis yang berbeda. Oleh karena itu, host tidak sebaiknya menetapkan harga hanya berdasarkan rata-rata umum kota, tetapi perlu membandingkan listing-nya dengan cluster yang paling relevan.

5.2 Interpretasi Model Prediksi Harga

Hasil model supervised menunjukkan bahwa XGBoost Regressor menjadi model terbaik berdasarkan R^2 dan MAE. Nilai R^2 sebesar 0,617 menunjukkan bahwa model mampu menjelaskan sekitar 61,7% variasi harga pada skala log. Nilai ini dapat dikategorikan cukup baik untuk data properti Airbnb karena harga akomodasi dipengaruhi oleh banyak faktor yang tidak seluruhnya tersedia dalam dataset, seperti fasilitas

properti, kualitas foto, jarak ke transportasi publik, jarak ke objek wisata, musim, event khusus, dan sentimen ulasan.


Nilai MAE XGBoost sebesar 48,395 berarti bahwa secara rata-rata prediksi harga model memiliki kesalahan sekitar 48,40 dolar per malam. Dalam konteks bisnis, nilai ini menunjukkan bahwa model dapat digunakan sebagai alat bantu awal dalam menentukan rentang harga, tetapi belum cukup ideal untuk sepenuhnya menggantikan keputusan manusia. Model dapat membantu host memperkirakan harga wajar berdasarkan fitur listing, namun keputusan akhir tetap perlu mempertimbangkan faktor eksternal dan kondisi aktual pasar.

Perbandingan antar model juga menunjukkan bahwa model non-linear lebih unggul dibandingkan model linier. Linear Regression menghasilkan MAE sebesar 54,222, sedangkan Random Forest dan XGBoost mampu menurunkan MAE menjadi sekitar 48 dolar. Hal ini membuktikan bahwa hubungan antara fitur listing dan harga Airbnb tidak sepenuhnya linier. Faktor seperti tipe kamar, lokasi, dan ketersediaan kemungkinan memiliki interaksi yang kompleks dalam menentukan harga.

Random Forest dan XGBoost memiliki performa yang sangat dekat. Random Forest memiliki RMSE lebih rendah, sedangkan XGBoost memiliki R^2 dan MAE sedikit lebih baik. Karena penelitian ini lebih menekankan rata-rata kesalahan prediksi harga yang mudah diinterpretasikan secara bisnis, XGBoost dipilih sebagai model terbaik.

5.3 Feature Importance / SHAP

Interpretasi fitur dilakukan menggunakan feature importance dari model XGBoost. Pada implementasi penelitian ini, SHAP belum digunakan sebagai metode utama, sehingga interpretasi diarahkan pada feature importance yang dihasilkan oleh model. Jika penelitian dikembangkan lebih lanjut, SHAP dapat ditambahkan untuk melihat arah pengaruh setiap fitur terhadap prediksi harga secara lebih detail.



Gambar 13. Top 10 Feature Importance XGBoost

Gambar ini menunjukkan fitur yang paling banyak digunakan oleh XGBoost dalam membentuk prediksi harga. Fitur `room_type_Private room`, `room_type_Shared room`, dan `neighbourhood_group_Manhattan` menjadi fitur paling dominan, diikuti oleh koordinat geografis dan fitur operasional listing.

Berdasarkan grafik Top 10 Feature Importance XGBoost, fitur yang paling berpengaruh terhadap prediksi harga adalah room_type_Private room, room_type_Shared room, neighbourhood_group_Manhattan, longitude, latitude, minimum_nights_capped, availability_365, neighbourhood_freq, number_of_reviews, dan calculated_host_listings_count.

Fitur room_type_Private room dan room_type_Shared room menjadi fitur paling penting karena tipe kamar secara langsung membedakan nilai ekonomi listing. Entire home/apt umumnya memiliki harga lebih tinggi karena tamu menyewa seluruh unit, sedangkan private room dan shared room memiliki harga lebih rendah karena ruang yang digunakan lebih terbatas. Oleh karena itu, perubahan kategori tipe kamar memberikan sinyal yang kuat bagi model dalam menentukan harga.

Fitur neighbourhood_group_Manhattan juga berpengaruh besar karena Manhattan merupakan wilayah dengan harga sewa tertinggi di NYC. Hal ini sejalan dengan hasil EDA yang menunjukkan bahwa Manhattan memiliki rata-rata dan median harga lebih tinggi dibandingkan borough lain. Dengan demikian, model berhasil menangkap bahwa lokasi administratif menjadi faktor penting dalam pembentukan harga.

Fitur longitude dan latitude menunjukkan bahwa posisi geografis listing juga penting. Dua listing yang berada dalam borough yang sama tetap dapat memiliki harga berbeda karena lokasinya lebih dekat atau lebih jauh dari pusat aktivitas kota, kawasan bisnis, objek wisata, atau transportasi. Oleh karena itu, koordinat geografis membantu model menangkap variasi lokasi yang lebih detail dibandingkan hanya menggunakan nama borough.

Fitur minimum_nights_capped berpengaruh karena kebijakan minimum menginap dapat mencerminkan strategi bisnis host. Listing dengan minimum nights tinggi cenderung menargetkan penyewa jangka panjang, sementara listing dengan minimum nights rendah lebih fleksibel untuk wisatawan harian. Perbedaan strategi ini berdampak pada struktur harga. Fitur availability_365 juga penting karena menunjukkan ketersediaan properti sepanjang tahun. Listing dengan availability tinggi dapat berarti properti memang didedikasikan untuk disewakan secara penuh, tetapi juga dapat menunjukkan permintaan yang belum optimal.

5.4 Strategi Pricing

Berdasarkan hasil EDA, clustering, dan model prediksi harga, strategi pricing yang dapat direkomendasikan adalah strategi berbasis segmen. Host tidak sebaiknya menetapkan harga hanya berdasarkan rata-rata harga seluruh listing NYC karena karakteristik setiap listing sangat berbeda. Harga perlu dibandingkan dengan listing dalam cluster yang sama dan tipe kamar yang sejenis.

Tabel 8. Rekomendasi Strategi Pricing Berdasarkan Segmen

Segmen	Strategi Pricing	Alasan
Budget Private Room	Tetapkan harga kompetitif di sekitar median cluster dan tonjolkan privasi	Konsumen sensitif harga tetapi tetap membutuhkan kenyamanan dasar

Standard Entire Home	Gunakan harga menengah dengan penyesuaian berdasarkan lokasi dan kapasitas	Cocok untuk keluarga/grup yang mencari unit penuh
Shared Room	Gunakan harga rendah dan fleksibilitas minimum nights	Target pasar sangat sensitif terhadap harga
Premium/Luxury	Tetapkan harga premium dengan fokus pada kualitas, fasilitas, dan pengalaman	Margin per pemesanan lebih penting daripada volume tinggi
Long-Term Stay	Gunakan diskon bulanan dan minimum nights tinggi	Target pasar adalah penyewa jangka menengah/panjang
High-Review Listing	Pertahankan harga kompetitif dan jaga reputasi ulasan	Listing aktif dapat memanfaatkan reputasi untuk menjaga demand

Untuk entire home/apt di Manhattan, strategi harga premium dapat diterapkan karena kombinasi tipe unit penuh dan lokasi strategis memiliki nilai ekonomi tinggi. Namun, host tetap perlu memperhatikan kompetitor dalam area yang sama agar harga tidak terlalu jauh dari pasar.

Untuk private room di Brooklyn dan Queens, strategi harga kompetitif lebih relevan. Kedua wilayah ini memiliki daya tarik bagi wisatawan yang ingin mendapatkan akses ke NYC dengan harga lebih terjangkau dibandingkan Manhattan. Host pada segmen ini sebaiknya menonjolkan nilai tambah seperti akses transportasi, kebersihan, keamanan, dan fleksibilitas check-in.

Untuk listing dengan availability tinggi, host perlu mengevaluasi apakah harga terlalu mahal, minimum nights terlalu kaku, atau deskripsi listing kurang menarik. Availability tinggi dapat menjadi sinyal bahwa listing belum optimal dalam menarik pemesanan. Strategi yang dapat diterapkan adalah penyesuaian harga, diskon pada periode sepi, promosi untuk durasi menginap tertentu, atau perbaikan kualitas foto dan deskripsi.

Untuk listing long-term stay, strategi harga sebaiknya diarahkan pada diskon bulanan dan stabilitas pendapatan. Host dapat menargetkan pekerja sementara, mahasiswa, ekspatriat, atau tamu yang membutuhkan tempat tinggal sementara selama beberapa minggu hingga bulan.

5.5 Rekomendasi untuk Host dan Platform

Berdasarkan hasil penelitian, beberapa rekomendasi untuk host Airbnb adalah sebagai berikut.

Pertama, host baru sebaiknya tidak langsung menetapkan harga berdasarkan intuisi pribadi. Harga awal perlu dibandingkan dengan listing dalam cluster yang sama. Misalnya, host dengan private room sebaiknya membandingkan harga dengan Cluster 0, bukan dengan seluruh listing NYC. Pendekatan ini membuat penetapan harga lebih adil dan sesuai dengan segmen pasar.

Kedua, host pada segmen budget perlu menonjolkan value. Karena konsumen dalam segmen ini sensitif terhadap harga, strategi yang efektif adalah memberikan harga kompetitif, fleksibilitas minimum nights, deskripsi yang jelas, foto yang baik, dan penekanan pada akses transportasi atau lokasi strategis.

Ketiga, host pada segmen premium perlu menekankan kualitas pengalaman. Listing premium tidak harus mengejar tingkat okupansi tertinggi, tetapi perlu memastikan bahwa harga tinggi didukung oleh fasilitas, desain interior, lokasi, layanan, dan reputasi yang sesuai. Ulasan positif menjadi sangat penting karena tamu premium memiliki ekspektasi tinggi.

Keempat, host pada segmen long-term stay perlu menyusun strategi khusus untuk penyewa jangka menengah. Strategi yang dapat digunakan adalah diskon bulanan, deskripsi fasilitas kerja jarak jauh, ketersediaan dapur, laundry, dan informasi akses transportasi. Segmen ini dapat memberikan pendapatan yang lebih stabil meskipun jumlah ulasan lebih rendah.

Kelima, host dengan listing high-review perlu menjaga konsistensi layanan. Cluster 5 menunjukkan bahwa listing dengan ulasan tinggi memiliki posisi kuat di pasar. Host dalam segmen ini sebaiknya menjaga kualitas layanan, merespons tamu dengan cepat, mempertahankan kebersihan, dan mengelola harga agar tetap kompetitif.

Selain bermanfaat bagi host, hasil penelitian ini juga dapat digunakan oleh platform Airbnb untuk meningkatkan kualitas layanan dan pengambilan keputusan berbasis data.

Pertama, platform dapat mengembangkan sistem rekomendasi harga berbasis cluster. Dengan mengetahui cluster suatu listing, platform dapat memberikan rekomendasi harga yang lebih spesifik dibandingkan rekomendasi berbasis rata-rata kota. Misalnya, rekomendasi harga untuk private room budget tentu berbeda dengan entire home premium.

Kedua, platform dapat memberikan insight kompetitor kepada host. Host dapat diberi informasi mengenai median harga, rata-rata ulasan, dan tingkat ketersediaan listing sejenis di area yang sama. Insight ini dapat membantu host memahami posisi listing-nya di pasar.

Ketiga, platform dapat menampilkan segmentasi listing untuk membantu konsumen. Misalnya, pengguna dapat diarahkan ke segmen budget, family stay, long-term stay, atau premium stay berdasarkan kebutuhan perjalanan. Dengan demikian, hasil clustering dapat digunakan tidak hanya untuk analisis internal, tetapi juga untuk meningkatkan pengalaman pencarian pengguna.

Keempat, platform dapat menggunakan model prediksi harga sebagai alat deteksi harga tidak wajar. Listing dengan harga yang terlalu tinggi atau terlalu rendah dibandingkan prediksi model dapat ditandai untuk ditinjau kembali. Hal ini dapat membantu menjaga kualitas pasar dan meningkatkan kepercayaan pengguna.

BAB 6

KESIMPULAN DAN SARAN

6.1 Kesimpulan

Berdasarkan hasil analisis dan pemodelan terhadap dataset Airbnb NYC 2019, diperoleh beberapa kesimpulan sebagai berikut.

Pertama, distribusi harga listing Airbnb NYC menunjukkan pola yang sangat miring ke kanan. Sebagian besar listing berada pada rentang harga umum, tetapi terdapat sejumlah kecil listing dengan harga sangat tinggi. Oleh karena itu, dilakukan outlier capping pada persentil ke-99 dan transformasi log agar data lebih stabil untuk pemodelan regresi.

Kedua, lokasi dan tipe kamar terbukti menjadi faktor penting dalam pembentukan harga. Manhattan merupakan wilayah dengan harga tertinggi, sedangkan Bronx menjadi salah satu wilayah paling terjangkau. Dari sisi tipe kamar, entire home/apt memiliki harga tertinggi, diikuti private room, kemudian shared room sebagai tipe kamar termurah.

Ketiga, pendekatan K-Means Clustering berhasil membentuk enam segmen pasar Airbnb NYC. Segmen tersebut mencakup budget private room, standard entire home, shared room murah, premium/luxury listing, long-term stay, dan high-review listing. Hasil ini menunjukkan bahwa pasar Airbnb NYC bersifat heterogen sehingga strategi harga dan pemasaran perlu disesuaikan dengan karakteristik segmen.

Keempat, hasil supervised learning menunjukkan bahwa model non-linear memiliki performa lebih baik dibandingkan model linier. XGBoost menghasilkan performa terbaik berdasarkan R^2 dan MAE, dengan R^2 sebesar 0,617 dan MAE sebesar 48,395. Hal ini menunjukkan bahwa hubungan antara karakteristik listing dan harga bersifat kompleks sehingga lebih cocok dimodelkan menggunakan algoritma ensemble berbasis pohon keputusan.

Kelima, eksperimen hybrid menunjukkan bahwa penambahan label cluster sebagai fitur tambahan dapat menurunkan nilai MAE. Namun, hasil tersebut perlu diinterpretasikan secara hati-hati karena cluster dibentuk menggunakan fitur price_capped, sehingga terdapat potensi data leakage jika label cluster digunakan kembali untuk memprediksi harga.

6.2 Model Terbaik

Model terbaik untuk prediksi harga adalah XGBoost Regressor. Model ini memperoleh R^2 sebesar 0,617, MAE sebesar 48,395, dan RMSE sebesar 94,471. XGBoost dipilih karena memiliki nilai R^2 tertinggi dan MAE terendah dibandingkan model lainnya. Meskipun Random Forest memiliki RMSE sedikit lebih rendah, XGBoost dinilai lebih unggul secara keseluruhan karena mampu memberikan keseimbangan terbaik antara akurasi rata-rata dan kemampuan menjelaskan variasi harga.

Model terbaik untuk segmentasi pasar adalah K-Means Clustering dengan $K=6$. Pemilihan ini didasarkan pada nilai Silhouette Score tertinggi sebesar 0,4975. Selain unggul secara metrik, hasil cluster juga memiliki makna bisnis yang jelas dan dapat digunakan untuk menyusun strategi harga serta segmentasi pasar.

Dengan demikian, pendekatan yang paling tepat untuk studi kasus ini adalah kombinasi supervised dan unsupervised learning. Supervised learning digunakan untuk prediksi harga, sedangkan unsupervised

learning digunakan untuk memahami segmentasi pasar. Jika harus memilih model final untuk kebutuhan prediksi harga, maka XGBoost menjadi pilihan utama. Jika tujuan utamanya adalah strategi bisnis dan pemetaan pasar, maka K-Means dengan $K=6$ menjadi pendekatan yang paling informatif.

6.3 Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan yang perlu diperhatikan.

Pertama, dataset yang digunakan hanya mencakup data Airbnb NYC tahun 2019. Oleh karena itu, hasil analisis tidak secara langsung merepresentasikan kondisi pasar Airbnb setelah tahun tersebut, terutama karena industri pariwisata dapat berubah akibat faktor ekonomi, regulasi, pandemi, dan perubahan tren perjalanan.

Kedua, penelitian ini tidak menggunakan data eksternal seperti jarak ke objek wisata, jarak ke stasiun transportasi, tingkat keamanan wilayah, musim, event kota, atau data ekonomi lokal. Padahal, faktor-faktor tersebut dapat memengaruhi harga akomodasi secara signifikan.

Ketiga, dataset tidak menyediakan informasi fasilitas detail properti, seperti jumlah kamar tidur, jumlah kamar mandi, fasilitas dapur, AC, Wi-Fi, elevator, atau kualitas foto listing. Ketiadaan fitur ini membatasi kemampuan model dalam membedakan kualitas properti secara lebih rinci.

Keempat, penelitian ini belum memanfaatkan analisis teks ulasan atau sentimen pengguna. Padahal, ulasan tamu dapat memberikan informasi penting mengenai kualitas layanan, kebersihan, kenyamanan, dan kepuasan pelanggan.

Kelima, hyperparameter tuning pada model supervised masih terbatas pada konfigurasi parameter terkontrol. Penelitian ini belum melakukan pencarian parameter secara luas menggunakan GridSearchCV atau RandomizedSearchCV karena mempertimbangkan efisiensi waktu dan komputasi.

Keenam, eksperimen hybrid memiliki potensi data leakage karena cluster dibentuk menggunakan `price_capped`, kemudian label cluster digunakan kembali sebagai fitur untuk memprediksi harga. Oleh karena itu, hasil hybrid tidak dijadikan sebagai model final utama, melainkan sebagai eksperimen tambahan.

6.4 Saran Pengembangan

Berdasarkan keterbatasan tersebut, terdapat beberapa saran pengembangan untuk penelitian selanjutnya.

Pertama, penelitian berikutnya dapat menambahkan data eksternal seperti jarak listing ke pusat kota, objek wisata, stasiun subway, bandara, atau kawasan bisnis. Penambahan fitur lokasi yang lebih kaya dapat membantu model memahami pengaruh aksesibilitas terhadap harga.

Kedua, penelitian selanjutnya dapat menggunakan informasi fasilitas properti jika tersedia. Fitur seperti jumlah kamar tidur, jumlah kamar mandi, fasilitas dapur, Wi-Fi, AC, dan fasilitas parkir kemungkinan besar dapat meningkatkan akurasi prediksi harga.

Ketiga, analisis teks ulasan dapat ditambahkan menggunakan Natural Language Processing. Sentimen ulasan dapat digunakan untuk menangkap persepsi tamu terhadap kualitas listing. Dengan demikian, model tidak hanya mempertimbangkan jumlah ulasan, tetapi juga isi dan kualitas ulasan.

Keempat, model lanjutan seperti LightGBM dan CatBoost dapat digunakan sebagai pembanding tambahan. Kedua algoritma tersebut dikenal kuat untuk data tabular dan dapat memberikan performa yang kompetitif, terutama ketika terdapat banyak fitur kategorikal.

Kelima, hyperparameter tuning perlu dilakukan secara lebih sistematis menggunakan GridSearchCV, RandomizedSearchCV, atau Bayesian Optimization. Dengan tuning yang lebih luas, performa model dapat diuji secara lebih optimal dan hasil perbandingan antar model menjadi lebih kuat.

Keenam, untuk pendekatan hybrid, clustering sebaiknya dilakukan tanpa menggunakan fitur target harga. Cluster dapat dibentuk dari fitur non-target seperti lokasi, tipe kamar, jumlah ulasan, ketersediaan, minimum nights, dan jumlah listing host. Dengan cara ini, label cluster dapat digunakan sebagai fitur tambahan tanpa risiko data leakage.

Ketujuh, validasi model dapat diperkuat menggunakan cross-validation. Pendekatan ini dapat memberikan gambaran performa model yang lebih stabil dibandingkan hanya menggunakan satu kali train-test split.

Secara keseluruhan, penelitian ini menunjukkan bahwa kombinasi analisis EDA, clustering, dan regresi mampu memberikan pemahaman yang lebih komprehensif terhadap pasar Airbnb NYC 2019. Hasil model tidak hanya dapat digunakan untuk prediksi harga, tetapi juga dapat diterjemahkan menjadi strategi bisnis yang lebih spesifik dan dapat ditindaklanjuti.

REFERENSI

- [1] M. Cheng and D. Edwards, "A comparative automated content analysis approach on the review of the sharing economy discourse in tourism and hospitality," *Current Issues in Tourism*, vol. 22, no. 1, pp. 35–49, Jan. 2019, doi: 10.1080/13683500.2017.1361908.
- [2] "(PDF) Komunikasi Pemasaran Hotel seiring bertumbuhnya Homestay Daring: Kasus Hotel Berbintang di Jawa." Accessed: May 04, 2026. [Online]. Available: https://www.researchgate.net/publication/347304889_Komunikasi_Pemasaran_Hotel_seiring_bertumbuhnya_Homestay_Daring_Kasus_Hotel_Berbintang_di_Jawa
- [3] Y. H. Akbar and A. Tracogna, "The sharing economy and the future of the hotel industry: Transaction cost theory and platform economics," *Int. J. Hosp. Manag.*, vol. 71, pp. 91–101, Apr. 2018, doi: 10.1016/J.IJHM.2017.12.004.
- [4] D. Buhalis and R. Leung, "Smart hospitality—Interconnectivity and interoperability towards an ecosystem," *Int. J. Hosp. Manag.*, vol. 71, pp. 41–50, Apr. 2018, doi: 10.1016/J.IJHM.2017.11.011.
- [5] R. Deboosere, D. J. Kerrigan, D. Wachsmuth, and A. El-Geneidy, "Location, location and professionalization: a multilevel hedonic analysis of Airbnb listing prices and revenue," *Reg. Stud. Reg. Sci.*, vol. 6, no. 1, pp. 143–156, Jan. 2019, doi: 10.1080/21681376.2019.1592699.
- [6] D. T. Tandel, "The Role of Cultural Organizations and Safety in Shaping Airbnb Hospitality in New York City," Jul. 2025, doi: 10.20944/PREPRINTS202507.1323.V1.
- [7] S. Moro, P. Rita, and C. Oliveira, "Factors Influencing Hotels' Online Prices," *Journal of Hospitality Marketing & Management*, 2018, doi: 10.1080/19368623.2018.1395379.
- [8] J. Kim, S. Kwon, and S. H. Park, "Adaptive Hotel Rate Prediction Using External Data: A Competitor-Driven Approach," *Proceedings of the Annual Hawaii International Conference on System Sciences*, pp. 1821–1830, 2025, doi: 10.24251/HICSS.2025.224.
- [9] G. V. C. Zambrano, F. Á. L. Quintero, D. N. Rivera, and Y. R. Alfonso, "Price Metric for the Improvement of Accommodation Service Offers in Sucre- San Vicente Tourist Destination," *International Journal of Professional Business Review*, vol. 8, no. 10, p. e3937, Oct. 2023, doi: 10.26668/BUSINESSREVIEW/2023.V8I10.3937.
- [10] O. Troisi, A. Visvizi, and M. Grimaldi, "Digitalizing business models in hospitality ecosystems: toward data-driven innovation," *European Journal of Innovation Management*, vol. 26, no. 7, pp. 242–277, Dec. 2023, doi: 10.1108/EJIM-09-2022-0540.
- [11] V. Pandey, J. Monteil, C. Gambella, and A. Simonetto, "On the needs for MaaS platforms to handle competition in ridesharing mobility," *Transp. Res. Part C Emerg. Technol.*, vol. 108, pp. 269–288, Nov. 2019, doi: 10.1016/J.TRC.2019.09.021.
- [12] C. H. Yu, "Exploratory Data Analysis," *Psychology*, Nov. 2017, doi: 10.1093/OBO/9780199828340-0200.
- [13] Mr. Shubneet, A. Raj Yadav, P. Chanda, and M. Y. Bin Taleb Abrar, "EXPLORATORY DATA ANALYSIS AND VISUALIZATION," *Artificial Intelligence Technology in Healthcare: Security and Privacy Issues*, pp. 56–70, Dec. 2025, doi: 10.58532/NBENNURAITH5.
- [14] Y. Radwan, "Analyzing Airbnb Listings in New York City", doi: 10.5281/ZENODO.17777617.
- [15] P. R. Kalehbasti, L. Nikolenko, and H. Rezaei, "Airbnb Price Prediction Using Machine Learning and Sentiment Analysis," *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 12844 LNCS, pp. 173–184, Jul. 2019, doi: 10.1007/978-3-030-84060-0_11.

- [16] N. Camatti, G. di Tollo, G. Filograsso, and S. Ghilardi, "Predicting Airbnb pricing: a comparative analysis of artificial intelligence and traditional approaches," *Computational Management Science*, vol. 21, no. 1, pp. 30-, Jun. 2024, doi: 10.1007/S10287-024-00511-4/FIGURES/2.
- [17] S. Morgenthaler, "Exploratory data analysis," *Wiley Interdiscip. Rev. Comput. Stat.*, vol. 1, no. 1, pp. 33–44, Jul. 2009, doi: 10.1002/WICS.2.
- [18] J. Shreffler and M. R. Huecker, "Exploratory Data Analysis: Frequencies, Descriptive Statistics, Histograms, and Boxplots," *StatPearls*, Nov. 2023, Accessed: May 04, 2026. [Online]. Available: <https://www.ncbi.nlm.nih.gov/books/NBK557570/>
- [19] C. Leys, C. Ley, O. Klein, P. Bernard, and L. Licata, "Detecting outliers: Do not use standard deviation around the mean, use absolute deviation around the median," *J. Exp. Soc. Psychol.*, vol. 49, no. 4, pp. 764–766, Jul. 2013, doi: 10.1016/J.JESP.2013.03.013.
- [20] W. S. Cleveland and R. McGill, "Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods," *J. Am. Stat. Assoc.*, vol. 79, no. 387, pp. 531–554, 1984, doi: 10.1080/01621459.1984.10478080.
- [21] D. Wang and J. L. Nicolau, "Price determinants of sharing economy based accommodation rental: A study of listings from 33 cities on Airbnb.com," *Int. J. Hosp. Manag.*, vol. 62, pp. 120–131, Apr. 2017, doi: 10.1016/J.IJHM.2016.12.007.
- [22] C. Chang and S. Li, "Study of price determinants of sharing economy-based accommodation services: Evidence from airbnb.com," *Journal of Theoretical and Applied Electronic Commerce Research*, vol. 16, no. 4, pp. 584–601, Jul. 2021, doi: 10.3390/JTAER16040035.
- [23] G. Boeing and P. Waddell, "New Insights into Rental Housing Markets Across the United States: Web Scraping and Analyzing Craigslist Rental Listings," *SSRN Electronic Journal*, Apr. 2018, doi: 10.2139/SSRN.2781297.
- [24] S. Chapman, S. M. And, and K. Villegas, "Predicting Listing Prices In Dynamic Short Term Rental Markets Using Machine Learning Models," Aug. 2023, Accessed: May 04, 2026. [Online]. Available: <https://arxiv.org/abs/2308.06929v1>

LAMPIRAN

```
1 # Download & Load Dataset
2 dataset_handle = "dgononov/new-york-city-airbnb-open-data"
3 path = kagglehub.dataset_download(dataset_handle)
4
5 selected_cols = [
6     "id", "host_id", "host_name", "neighbourhood_group", "neighbourhood",
7     "latitude", "longitude", "room_type", "price", "minimum_nights",
8     "number_of_reviews", "last_review", "reviews_per_month",
9     "calculated_host_listings_count", "availability_365"
10 ]
11 df_raw = pd.read_csv(f"{path}/AB_NYC_2019.csv", usecols=selected_cols)
12
13 # Pembersihan Data (sesuai EDA)
14 mask_valid = (
15     (df_raw["price"] > 0)
16     & (df_raw["availability_365"].between(0, 365))
17     & (df_raw["latitude"].between(40.45, 40.95))
18     & (df_raw["longitude"].between(-74.30, -73.65))
19 )
20 df_clean = df_raw.loc[mask_valid].copy()
21
22 # Penanganan Outlier: Batasi Price dan Minimum Nights di Quantile 99%
23 price_hi = df_clean["price"].quantile(0.99)
24 min_nights_hi = df_clean["minimum_nights"].quantile(0.99)
25
26 df_clean["price_capped"] = df_clean["price"].clip(upper=price_hi)
27 df_clean["minimum_nights_capped"] = df_clean["minimum_nights"].clip(upper=min_nights_hi)
28
29 # Split Dataset
30 df_full = df_clean.copy()
31 df_sample = df_full.sample(min(15000, len(df_full)), random_state=42).copy()
32
33 print(f>Data Full: {len(df_full)} baris")
34 print(f>Data Sample: {len(df_sample)} baris")
```

